

# Prepoznavanje raka pluća i debelog crijeva na slikama koristeći CNN

1<sup>st</sup> Dominik Jambrović<sup>2<sup>nd</sup></sup> Filip Pankretić<sup>3<sup>rd</sup></sup> Velimir Kovačić<sup>4<sup>th</sup></sup> Filip Perković<sup>5<sup>th</sup></sup> Luka Glavinić<sup>6<sup>th</sup></sup> Neven Krznar  
FER FER FER FER FER FER

## I. OPIS PROBLEMA I MOTIVACIJA

Rak je jedna od najsmrtonosnijih bolesti na svijetu. Svake godine izvještaji pokazuju preko 19 milijuna novih slučajeva i oko 10 milijuna smrtnih slučajeva [1]. Rak ima mnogo mogućih uzročnika: UV zračenja, pušenja cigareta, udisanja kancerogenih plinova, nasljednih bolesti i tako dalje.

Općenito, stanice ljudskog tijela svaki dan umiru i zamjenjuju se novima procesom staničnog dijeljenja. Zbog ogromnog broja stanica koje čine naše tijelo, u ovim procesima može doći do greške neispravnim repliciranjem molekule DNK.

Stanice u kojima dođe do toga nazivaju se tumorskim stanicama. Tumori mogu biti zloćudni ili dobroćudni. Zloćudni tumori dovode do raka koji može zahvatiti gotovo svaki organ ljudskog tijela.

Od raka obolijevaju i muškarci i žene, a najčešći oblici su rak crijeva, pluća, jetre, dojke, rektuma, mozga, prostate, želuca te kože.

Od raka pluća i raka crijeva otprilike jednakom mjerom obolijevaju i muškarci i žene, zbog čega će njihovo otkrivanje biti fokus ovoga rada.

Za rak još uvijek nema lijeka, nego postoje samo tretmani koji mogu biti učinkoviti ako je rak otkriven što ranije. Zbog ovoga su znanstvenici i doktori medicine diljem svijeta počeli tražiti rješenje za ovu bolest u područjima dubokog učenja i računarske znanosti.

Motivacija ovog rada je pokazati kako se pomoću umjetnih neuronskih mreža može obavljati bolje predviđanje prirode stanica tkiva slikanih medicinskim instrumentima i time pomoći stručnjacima dijagnosticirati pacijente.

U ovome radu prvo će se opisati postojeća rješenja problema. Dalje, opisat će se korišteni skup podataka i korištene neuronske mreže, a nakon toga prikazati njihovi rezultati. Na kraju će se prodiskutirati i usporediti rezultati tuđih pristupa i našeg pristupa i dati zaključak.

## II. PREGLED POSTOJEĆIH RJEŠENJA

Prema [2], do sada je provedeno mnogo prijašnjih istraživanja na ovu temu, a predložena su i neka rješenja s obećavajućim rezultatima. U ovom poglavlju pričat će se samo o radovima iz domene raka pluća i raka debelog crijeva jer je to tema našeg rada. Rješenja variraju po tipovima slika korištenih za treniranje modela, metodama za procesiranje slika, karakteristikama izvučenih iz svake slike i arhitekturama modela. U radu [3] predložena je prostorno ograničena neuronska mreža za detektiranje jezgre u histopatološkim slikama

stanica raka crijeva koja je postigla najveću točnost od 97.1%.

U radu [4] razvijena je metoda za klasificiranje stanica raka iz jezgri stanica dobivenih biopsijom iglom i segmentiranih na 4372 regije. Postigli su konačnu točnost od 88.1%. Dalje, u radu iz 2014. [5] predložena je CAD metoda za klasifikaciju raka pluća temeljena na dvije umjetne neuronske mreže, jedna s unaprijednom propagacijom, a druga s jednom unaprijednom i unatražnom propagacijom. Postignuta ukupna točnost iznosila je 93.3%. Također, u [6] je razvijena metoda za analizu invazivnih plućnih čvorova pomoću slika dobivenih PET skeniranjem i dobivena je visoka točnost njihovog otkrivanja. U 2016. opisana je prostorno ograničena CNN metoda za detekciju i klasifikaciju jezgara tumorskih stanica raka crijeva. Metoda funkcionira pomoću histopatoloških slika i bez potrebe segmentacije [7]. Metoda je razvijena bez potrebe označavanja slika za ocjenjivanje raka crijeva [8]. U radu su korištene slike infracrvene histopatologije. Klasifikacija se radila pomoću nadziranog učenja temeljenog na stablu odluke. Ukupna dobivena točnost iznosila je 99%. U 2017. razvijena je metoda za klasifikaciju zloćudnih čvorova pluća, za koju nije bila potrebna ni segmentacija ni izvlačenje značajki [9]. Autori su se u cijelosti pouzdali u svoj model strojnog učenja i postigli točnost od 87.14%. Dalje, prema [10] korištena je i istrenirana konvolucijska neuronska mreža za otkrivanje prisustva raka pluća na 134,668 CT skenova. Postignuta je točnost od 89.9%. Prema radu [11] opisana je metoda dubokog učenja za otkrivanje polipa iz videa kolonoskopije. Za klasifikaciju je korištena umjetna neuronska mreža AlexNet, što je rezultiralo s 91.47% točnosti klasifikacije. Godine 2018. predložena je metoda za predviđanje raka pluća [12] koristeći optimizaciju roja svitaca (GSO) sa slikama iz različitih izvora i s povratnom neuronskom mrežom (RNN) kao algoritmom učenja. Dobivena je maksimalna točnost iznosa 98%. U [13] predložena je metoda identifikacije raka pluća pomoću konvolucijske neuronske mreže i testirana na preko 50,500 slika CT skenova. Postignuta je točnost od 92.63%. Prema radu [14] predložena je metoda za identificiranje zloćudnih čvorova u plućima koristeći ResNet50 i postignuta je točnost od 93.19%. U [15] je opisana razvijena CAD metoda za otkrivanje raka pluća i klasifikaciju stadija raka. Korištena je konvolucijska neuronska mreža (CNN) i DFCNet u ispitivanju na 6 različitih skupova podataka. Postignuta je točnost od 89.52%. Nadalje, u [16] je opisan RF-temeljen klasifikacijski model za predviđanje prisustva raka crijeva analizirajući histopatološke slike raka. Izvlačenje značajki obavljeno je dekompozicijom valnih du-


ljina slika. Postignuta je maksimalna točnost klasifikacije od 85.4%. Rad [17] opisuje metodu temeljenu na brzom R-CNN-u za pronalazak raka crijeva. Korištena je aproksimativna zglobna optimizacija koja optimira klasifikacijske i regresijske gubitke istovremeno. Postignuta je točnost od 98.5%. Dalje, rad [18] razvio je metodu za klasifikaciju polipa iz slika kolonoskopije s točnošću od 96%. Koristili su konvolucijsku neuronsku mrežu treniranu na ručno označenim slikama 2000 pacijenata. Godine 2019. u radu [19] predstavljena je metoda za automatsko otkrivanje raka pluća temeljena na slikama CT skenova. Najzanimljiviji dio ovog rada jest da su autori upotrijebili učenje ansambla generaliziranih neuronskih mreža koristeći diskretni *AdaBoost* algoritam (DAELGNN) i postigli impresivnu točnost od 99%. Cilj rada [20] bio je klasificirati izglednost raka crijeva pomoću infracrvenih Fourierovih transformnih spektroskopskih signala. Autori su dobili nekoliko statističkih značajki iz tih signala i koristili stroj potpornih vektora (SVM) i umjetne neuronske mreže (ANN) kako bi ih klasificirali i dobili točnost od 95.71%. Godine 2020. Suresh i Mohan [21] opisali su metodu za klasifikaciju raka pluća i dijagnozu vrste raka pomoću regije interesa (ROI) vrste učenja konvolucijske neuronske mreže. Dobili su točnost klasifikacije od 93.9%. Nadalje, u radu [22] testiran je model za otkrivanje plućnih čvorova temeljen na slikama CT skenova s plitkom konvolucijskom mrežom. Testirana je na LIDC skupu podataka i dobivena je klasifikacijska točnost od 97.9%. [23] je predložio još jednu metodu za otkrivanje raka pluća pomoću slika CT skenova. Micanjem šuma sa slika, upotrijebili su unaprijeđenu konvolucijsku mrežu (IDNN) za segmentaciju slike i mnogo metoda ansambla (EM) za klasifikaciju slika i dobili točnost od 96.2%.

### III. KORIŠTENI SKUP PODATAKA

Za potrebe ovog rada, korišten je skup podataka *LC25000*, objavljen 2020. [24] Sastoji se od 25000 slika tkiva pluća i debelog crijeva koje se dijele u 5 razreda:

- Adenokarcinom plućnog tkiva
- Karcinom pločastih (skvamoznih) stanica plućnog tkiva
- Dobroćudno (benigno) plućno tkivo
- Adenokarcinom tkiva debelog crijeva
- Dobroćudno (benigno) tkivo debelog crijeva

Skup se sastoji od 1250 jedinstvenih slika čiji je broj povećan rotacijama i zrcaljenjem na 25000. Svaki razred ima 5000 pripadnih slika. Sve su slike veličine 768 x 768 piksela.




**Slika 1:** Prikaz 9 slučajno odabranih slika tkiva iz skupa podataka

### IV. KONVOLUCIJSKE NEURONSKE MREŽE

Konvolucijska neuronska mreža inačica je višeslojnog perceptrona koja se temelji na filtriranju slike (konvoluciji). Mreža je nadahnuta povezanošću neurona u vidnoj kori ljudskog mozga. Takva je mreža deterministička i pogodna za analizu slika.

Sastoji se od niza konvolucijskih slojeva isprekidanih slojevima sažimanja. Na kraju mreže može biti postavljen klasični višeslojni perceptron kojim se uspostavlja veza između mapi značajki i traženih izlaza.



**Slika 2:** Primjer konvolucijske neuronske mreže za klasifikaciju vozila [25]

Konvolucijski sloj primjenjuje filtere (u obliku neurona) od kojih je svaki zadužen za pojedinu značajku. Rezultat primjene tih filtara naziva se mapa značajki. Svaki se filter primjenjuje na svim mapama značajki prethodnog sloja, a pritom su težine neurona iste ili slične. Takav sloj je neovisan o translaciji, ali ima ograničenu robusnost na rotaciju.

Sloj sažimanja služi za smanjenje veličine ulaza. Uz to umanjuje utjecaj pomaka značajki u prostoru.

Konvolucijska neuronska mreža uči se postupkom propagacije unatrag (često uz korištenje minigrupa). Kod propagacije unatrag postoji problem iščezavanja gradijenta zbog velikog broja slojeva. Prilikom praktične izvedbe učenja često je problem nedostatak memorije GPU. Može se zaobići korištenjem slobodno dostupnih predtreniranih slojeva mreže.

### V. MATERIJALI I METODE

Skup podataka *LC25000* podijeljen je na 3 disjunktna podskupa: skup za učenje (70% podataka), skup za validaciju

(10% podataka) i skup za testiranje (20% podataka). Skup za validaciju služi za odabir optimalnog modela prilikom učenja, a skup za testiranje služi za mjerenje performansi modela na neviđenim podacima nakon učenja. Same slike nisu prilagođavane, nego dovođene na ulaz neuronske mreže onakve kakve jesu. Dodatno, prilikom učenja korištene su minigrupe od po 16 slika. Korištena su 2 modela: *ResNet50* i *MobileNetV2*.

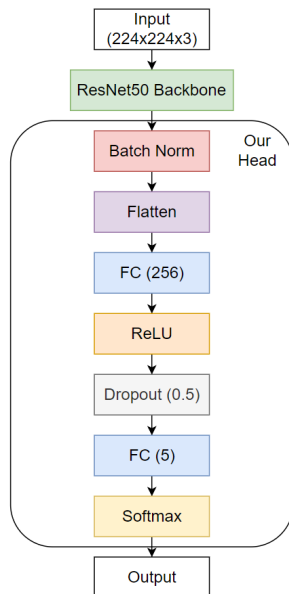
Radi povećanja učinkovitosti, osnovni slojevi modela inicijalizirani su parametrima dobivenim predtreniranjem na skupu podataka *ImageNet*. To je skup s preko 14 milijuna slika i više od 20 tisuća razreda. Ovo se naziva prijenosno učenje (TL); koristimo prethodno naučeno znanje kako bismo poboljšali performanse i skratili učenje našeg modela.

#### A. ResNet50

Kao temelj prvog modela korištena je konvolucijska neuronska mreža s 50 slojeva *ResNet50*. Ona ima 48 konvolucijskih slojeva, jedan sloj *MaxPool* i jedan sloj *Average pooling*.

Glavna su inovacija u *ResNet50* rezidualne (preskočne) veze, koje omogućuju mreži da nauči rezidualne funkcije za mapiranje ulaza na tražene izlaze. Omogućuje veću dubinu mreža bez problema iščezavanja gradijenta.

Prednaučena je na skupu podataka *ImageNet*. Dodana su još 4 skrivena te 1 izlazni sloj. Skriveni slojevi su redom: *BatchNormalization*, *Flatten*, potpuno povezani sloj *Dense* s aktivacijskom funkcijom *ReLu* i *Dropout*. Izlazni sloj je potpuno povezani sloj *Dense* s aktivacijskom funkcijom *softmax*. Skriveni sloj *Dropout* koristi se samo za vrijeme treniranja, ignorira određeni postotak veza u pojedinom koraku učenja i na taj način sprječava prenaučenosť.



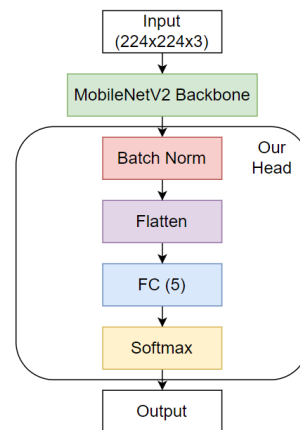
Slika 3: Arhitektura korištenog modela ResNet50

Model *ResNet50* ima 55 slojeva i 49287557 parametara, od kojih je 25695749 njih učivo jer se predtrenirani slojevi nisu učili. Učenje modela provedeno je kroz 60 epoha.

#### B. MobileNetV2

Drugi model temeljen je na konvolucijskoj neuronskoj mreži s rezidualnim vezama *MobileNetV2*. Sastoji se od 53 konvolucijska sloja, a osmišljena je kako bi učinkovito radila na mobilnim uređajima zahvaljujući manjem broju parametara. Uvodi novu vrstu bloka *Inverted Residuals* i konvolucijski sloj *Linear Bottleneck*. U bloku *Inverted Residuals*, značajke nižih dimenzija preslikavaju se u više dimenzije, zatim se primjenjuje konvolucijski sloj *Depthwise*, nakon čega se dimenzije značajki ponovno snižavaju na početne. Sloj *Linear Bottleneck* konvolucijski je sloj *Bottleneck* s linearnom aktivacijskom funkcijom.

Prednaučena je na skupu podataka *ImageNet*. Dodana su još 2 skrivena te 1 izlazni sloj. Skriveni slojevi su *Batch-Normalization* i *Flatten*. Izlazni sloj je *Dense* s aktivacijskom funkcijom *softmax*.



Slika 4: Arhitektura korištenog modela MobileNetV2

Model *MobileNetV2* ima 56 slojeva i 2576709 parametara, od kojih je 2540037 njih učivo. Za razliku od modela *ResNet50*, uče se i prednaučeni slojevi zbog manjeg broja parametara. Učenje modela provedeno je kroz 60 epoha.

## VI. REZULTATI I USPOREDBA S PRIJAŠNIM RADOVIMA

#### A. Prijašnji radovi

Radovi s kojima će se rezultati uspoređivati su [26] i [27].


U radu [26] koristi se konvolucijska neuronska mreža *AlexNet* s preko 60 milijuna parametara (za usporedbu, *ResNet50* ima nešto manje od 50 milijuna). Sastoji se od 5 konvolucijskih slojeva i 3 potpuno povezana sloja. Skup podataka podijeljen je na skup za učenje (80%) i skup za testiranje (20%). Učenje je provedeno kroz 60 epoha. Na slikama iz razreda s lošijim rezultatima, primijenjena je metoda *Histogram equalization* radi poboljšanja kontrasta. Taj postupak naziva se CSIP (*Class Selective Image Processing*).

U [27] glavni je fokus na pretprocesiranju skupa podataka. Povećava se oštrina slika metodom USM (*Unsharp masking*) i radi se izlučivanje 2D Fourierovih značajki i 2D *Wavelet* značajki koje se na kraju kombiniraju. Koristi se vlastita


konvolucijska neuronska mreža s 3 konvolucijska sloja, 2 sloja *MaxPool*, slojem *BatchNormalization* i slojem *Dropout*. Učenje je provedeno kroz 500 epoha. Skup podataka podijeljen je na skup za učenje (70%) i skup za testiranje (30%)

### B. Točnost i gubitak

Za oba modela prikazani su grafovi točnosti i gubitka na skupu za učenje i skupu za validaciju tijekom procesa učenja (slike 5 i 6).



**Slika 5:** Točnost (lijevo) i gubitak (desno) modela ResNet50 nad podacima za treniranje i validaciju po epohama



**Slika 6:** Točnost (lijevo) i gubitak (desno) modela MobileNetV2 nad podacima za treniranje i validaciju po epohama

Tablicom I usporedno su prikazane točnosti predviđanja naših modela i modela iz prijašnjih radova nakon učenja. Primjetno je da model *ResNet50* ima veću točnost (99.32%) na skupu za testiranje od modela *MobileNetV2* (98.65%), ali i da oba imaju veću točnost od modela iz prijašnjih radova [26] i [27].

**Tablica I:** Usporedni prikaz točnosti modela

Model	Točnost	
	Skup za učenje	Skup za testiranje
<b>ResNet50</b>	<b>99.45%</b>	<b>99.32%</b>
MobileNetV2	99.78%	98.65%
AlexNet [26]	99.85%	98.40%
CNN [27]	98.87%	96.33%


### C. Matrica zabune

Matrice zabune, računate na skupu za testiranje, prikazane su za oba naša modela (slike 7 i 8). Uz to su prikazane i matrice zabune modela iz radova [26] i [27] (slike 9 i 10).

Radi lakšeg snalaženja na matrici zabune, u tablici II predstavljene su brojčane oznake pojedinih razreda.

**Tablica II:** Oznake razreda na grafu


Oznaka	Razred
0	Adenokarcinom tkiva debelog crijeva
1	Dobroćudno (benigno) tkivo debelog crijeva
2	Adenokarcinom plućnog tkiva
3	Dobroćudno (benigno) plućno tkivo
4	Karcinom pločastih (skvamoznih) stanica plućnog tkiva




**Slika 7:** ResNet50



**Slika 9:** AlexNet [26]



**Slika 8:** MobileNetV2



**Slika 10:** CNN [27]

**Slika 11:** Matrice zabune 4 razmatrana modela

Model *ResNet50* ima općenito najmanje pogrešnih klasifikacija, 0.68%. *MobileNetV2* ima 1.16%, *AlexNet* [26] ima 1.62% i *CNN* [27] ima 3.67% pogrešnih klasifikacija.

*ResNet50*, *MobileNetV2* i *CNN* [27] imaju problema s razlikovanjem adenokarcinoma i karcinoma pločastih stanica plućnog tkiva. Uspješno raspoznaje radi li se o karcinomu ili ne, ali teže određuje vrstu karcinoma na plućnom tkivu. To implicira bliskost tih grupa slika u ulaznom prostoru i odgovara prirodi problema.

*AlexNet* [26] taj problem nema, ali ima više manjih pogrešaka između razreda.

## VII. MJERE DOBROTE

Konačno, za svaki razred u oba naša modela dan je stupčasti dijagram sljedećih mjera dobrote: točnost (1), preciznost (2), odziv (3), F1 (4) i specifičnost (5) (slike 12 i 13). Isti podaci prikazani su tablično (tablice III i IV). Tablica V usporedno

prikazuje prosječne mjere dobrote nad svim klasama za naše modele i modele iz prijašnjih radova.


$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

$$Precision = \frac{TP}{TP + FP} \quad (2)$$


$$Recall = \frac{TP}{TP + FN} \quad (3)$$

$$F1 = \frac{TP}{TP + 0.5(FN + FP)} \quad (4)$$

$$Specificity = \frac{TN}{TN + FP} \quad (5)$$



Slika 12: Mjere dobrote modela ResNet50



Slika 13: Mjere dobrote modela MobileNetV2

Tablica III: Mjere dobrote razreda za model ResNet50

Razred	Točnost	Preciznost	F1	Odziv	Specifičnost
0	99.92%	100%	99.8%	99.6%	100%
1	99.92%	99.58%	99.79%	100%	99.9%
2	99.4%	98.27%	98.47%	98.67%	99.58%
3	99.98%	100%	99.95%	99.9%	100%
4	99.98%	100%	99.95%	99.9%	100%

Tablica IV: Mjere dobrote razreda za model MobileNetV2

Razred	Točnost	Preciznost	F1	Odziv	Specifičnost
0	99.62%	100%	99.05%	98.12%	100%
1	99.82%	99.07%	99.53%	100%	99.78%
2	98.94%	98.57%	97.34%	96.13%	99.65%
3	100%	100%	100%	100%	100%
4	98.94%	95.72%	97.37%	99.09%	98.9%

Kao i prilikom analize matrica zabune, može se vidjeti da su mjere oba modela lošije kada se razmatraju razredi karcinoma plućnog tkiva. Oba modela teže raspoznaju karcinom pločastih stanica i adenokarcinom plućnog tkiva. *MobileNetV2* ima lošije mjere od *ResNet50* na svim razredima osim na

dobročudnom plućnom tkivu, koje je klasificirao potpuno točno.

Tablica V: Prosječne mjere dobrote za sve modele

Model	Točnost	Preciznost	F1	Specifičnost
<b>ResNet50</b>	<b>99.73%</b>	<b>99.32%</b>	<b>99.32%</b>	<b>99.83%</b>
MobileNetV2	99.46%	98.67%	98.66%	99.67%
AlexNet [26]	99.35%	98.39%	98.38%	99.60%
CNN [27]	96.33%	96.39%	96.38%	96.37%

Usporednom analizom mjera naših modela i modela iz prijašnjih radova, vidi se da naši modeli imaju bolji rezultat po svim korištenim mjerilima. Mjera za odziv nije prikazana jer nije prikazana u [27].

## VIII. ZAKLJUČAK

U ovom radu opisane su dvije metode za klasifikaciju raka debelog crijeva, dviju varijanti raka pluća i dviju vrsti benignih tkiva pomoću dvije mreže. Opisani su podaci nad kojima su metode testirane i prijašnji radovi koji su predložili rješenja na temu. Nakon provedenih eksperimenata opisani su vrlo zadovoljavajući rezultati i dane su usporedbe s prijašnjim radovima. Naša je metoda u usporedbi s onom iz rada kojeg smo uzeli za glavni uzor dala bolje rezultate. Također smo predstavili metodu koja ne samo da ne iziskuje pretprocesiranje slika, već i sadrži značajno manji skup parametara (*MobileNetV2*), što daje motivaciju za daljnja istraživanja s njime i laku mobilizaciju i primjenu u stvarnoj medicinskoj industriji. Ovo je područje koje se širi ubrzanom tempom i sadrži još mnogo prostora za daljnji rast i novo proučavanje. Radovi na ovu temu su od izrazite važnosti jer mogu spasiti milijune ljudskih života od ove strašne bolesti.

## LITERATURA

- [1] W. H. Organization *et al.*, "International agency for research on cancer," 2019.
- [2] S. Mehmood, T. M. Ghazal, M. A. Khan, M. Zubair, M. T. Naseem, T. Faiz, and M. Ahmad, "Malignancy detection in lung and colon histopathology images using transfer learning with class selective image processing," *IEEE Access*, vol. 10, pp. 25657–25668, 2022.
- [3] K. Sirinukunwattana, S. E. A. Raza, Y.-W. Tsang, D. R. J. Snead, I. A. Cree, and N. M. Rajpoot, "Locality sensitive deep learning for detection and classification of nuclei in routine colon cancer histology images," *IEEE Transactions on Medical Imaging*, vol. 35, no. 5, pp. 1196–1206, 2016.
- [4] Y. Shi, Y. Gao, Y. Yang, Y. Zhang, and D. Wang, "Multimodal sparse representation-based classification for lung needle biopsy images," *IEEE Transactions on Biomedical Engineering*, vol. 60, no. 10, pp. 2675–2685, 2013.
- [5] J. Kuruvilla and K. Gunavathi, "Lung cancer classification using neural networks for ct images," *Computer methods and programs in biomedicine*, vol. 113, no. 1, pp. 202–209, 2014.
- [6] S. A. Deppen, J. D. Blume, C. D. Kensinger, A. M. Morgan, M. C. Aldrich, P. P. Massion, R. C. Walker, M. L. McPheeters, J. B. Putnam, and E. L. Grogan, "Accuracy of fdg-pet to diagnose lung cancer in areas with infectious lung disease: a meta-analysis," *Jama*, vol. 312, no. 12, pp. 1227–1236, 2014.
- [7] K. Sirinukunwattana, S. E. A. Raza, Y.-W. Tsang, D. R. Snead, I. A. Cree, and N. M. Rajpoot, "Locality sensitive deep learning for detection and classification of nuclei in routine colon cancer histology images," *IEEE transactions on medical imaging*, vol. 35, no. 5, pp. 1196–1206, 2016.



- [8] C. Kuepper, F. Großerueschkamp, A. Kallenbach-Thieltges, A. Mosig, A. Tannapfel, and K. Gerwert, "Label-free classification of colon cancer grading using infrared spectral histopathology," *Faraday discussions*, vol. 187, pp. 105–118, 2016.
- [9] W. Shen, M. Zhou, F. Yang, D. Yu, D. Dong, C. Yang, Y. Zang, and J. Tian, "Multi-crop convolutional neural networks for lung nodule malignancy suspiciousness classification," *Pattern Recognition*, vol. 61, pp. 663–673, 2017.
- [10] W. Sun, B. Zheng, and W. Qian, "Automatic feature learning using multichannel roi based on deep structured algorithms for computerized lung cancer diagnosis," *Computers in biology and medicine*, vol. 89, pp. 530–539, 2017.
- [11] Z. Yuan, M. Izadyazdanabadi, D. Mokkapat, R. Panvalkar, J. Y. Shin, N. Tajbakhsh, S. Gurudu, and J. Liang, "Automatic polyp detection in colonoscopy videos," in *Medical Imaging 2017: Image Processing*, vol. 10133, pp. 718–727, SPIE, 2017.
- [12] R. Selvanambi, J. Natarajan, M. Karupiah, S. H. Islam, M. M. Hassan, and G. Fortino, "Lung cancer prediction using higher-order recurrent neural network based on glowworm swarm optimization," *Neural Computing and Applications*, vol. 32, pp. 4373–4386, 2020.
- [13] A. O. de Carvalho Filho, A. C. Silva, A. C. de Paiva, R. A. Nunes, and M. Gattass, "Classification of patterns of benignity and malignancy based on ct using topology-based phylogenetic diversity index and convolutional neural network," *Pattern Recognition*, vol. 81, pp. 200–212, 2018.
- [14] R. V. M. Da Nobrega, P. P. Reboucas Filho, M. B. Rodrigues, S. P. Da Silva, C. M. Dourado Júnior, and V. H. C. de Albuquerque, "Lung nodule malignancy classification in chest computed tomography images using transfer learning and convolutional neural networks," *Neural Computing and Applications*, vol. 32, pp. 11065–11082, 2020.
- [15] A. Masood, B. Sheng, P. Li, X. Hou, X. Wei, J. Qin, and D. Feng, "Computer-assisted decision support system in pulmonary cancer detection and stage classification on ct images," *Journal of biomedical informatics*, vol. 79, pp. 117–128, 2018.
- [16] T. Babu, D. Gupta, T. Singh, and S. Hameed, "Colon cancer prediction on different magnified colon biopsy images," in *2018 Tenth International Conference on Advanced Computing (ICoAC)*, pp. 277–280, IEEE, 2018.
- [17] X. Mo, K. Tao, Q. Wang, and G. Wang, "An efficient approach for polyps detection in endoscopic videos based on faster r-cnn," in *2018 24th international conference on pattern recognition (ICPR)*, pp. 3929–3934, IEEE, 2018.
- [18] G. Urban, P. Tripathi, T. Alkayali, M. Mittal, F. Jalali, W. Karnes, and P. Baldi, "Deep learning localizes and identifies polyps in real time with 96% accuracy in screening colonoscopy," *Gastroenterology*, vol. 155, no. 4, pp. 1069–1078, 2018.
- [19] P. M. Shakeel, A. Tolba, Z. Al-Makhadmeh, and M. M. Jaber, "Automatic detection of lung cancer from biomedical data set using discrete adaboost optimized ensemble learning generalized neural networks," *Neural Computing and Applications*, vol. 32, pp. 777–790, 2020.
- [20] S. Toraman, M. GİRĞİN, B. ÜSTÜNDAĞ, and I. Turkoglu, "Classification of the likelihood of colon cancer with machine learning techniques using ftir signals obtained from plasma," *Turkish Journal of Electrical Engineering and Computer Sciences*, vol. 27, no. 3, pp. 1765–1779, 2019.
- [21] S. Suresh and S. Mohan, "Roi-based feature learning for efficient true positive prediction using convolutional neural network for lung cancer diagnosis," *Neural Computing and Applications*, vol. 32, no. 20, pp. 15989–16009, 2020.
- [22] M. Masud, G. Muhammad, M. S. Hossain, H. Alhumyani, S. S. Alshamrani, O. Cheikhrouhou, and S. Ibrahim, "Light deep model for pulmonary nodule detection from ct scan images for mobile devices," *Wireless Communications and Mobile Computing*, vol. 2020, pp. 1–8, 2020.
- [23] P. M. Shakeel, M. Burhanuddin, and M. I. Desa, "Automatic lung cancer detection from ct image using improved deep neural network and ensemble classifier," *Neural Computing and Applications*, pp. 1–14, 2022.
- [24] A. A. Borkowski, M. M. Bui, L. B. Thomas, C. P. Wilson, L. A. DeLand, and S. M. Mastorides, "Lung and colon cancer histopathological image dataset (lc25000)," 2019.
- [25] S. Saha, "A guide to convolutional neural networks - the eli5 way," Nov 2023.
- [26] S. Mehmood, T. M. Ghazal, M. A. Khan, M. Zubair, M. T. Naseem, T. Faiz, and M. Ahmad, "Malignancy detection in lung and colon histopathology images using transfer learning with class selective image processing," *IEEE Access*, vol. 10, pp. 25657–25668, 2022.
- [27] M. Masud, N. Sikder, A.-A. Nahid, A. K. Bairagi, and M. A. AlZain, "A machine learning approach to diagnosing lung and colon cancer using a deep learning-based classification framework," *Sensors*, vol. 21, no. 3, 2021.